

Matemáticas para Quant Finance

Guía de base · Quantum Club

Este documento cubre todo el bagaje matemático que necesitas para abordar el curso Quant Club desde cero. No asume conocimientos previos más allá del bachillerato, pero tampoco se detiene en lo trivial: cada concepto se explica con la intuición primero, la fórmula después y un ejemplo financiero al final.

Cap	Tema	Para qué sirve en el curso
1	Funciones y logaritmos	Precios, retornos, escala logarítmica
2	Cálculo diferencial	Derivadas, Greeks, sensibilidades
3	Cálculo integral	Esperanzas, distribuciones acumuladas
4	Álgebra lineal	Carteras, correlaciones, simulación multidimensional
5	Probabilidad	Modelado de la incertidumbre en precios
6	Estadística	Retornos, volatilidad, ajuste de modelos
7	Procesos estocásticos (intro)	Movimiento Browniano, MBG, Black-Scholes

1.1 ¿Qué es una función?

Una función es una regla que toma un valor de entrada y produce exactamente un valor de salida. En finanzas, casi todo se expresa como funciones: el precio de una opción depende del precio del subyacente, del tiempo y de la volatilidad.

$$f(x) = y \rightarrow \text{a cada } x \text{ le corresponde un único } y$$

Ejemplo: $f(S)$ = precio de la opción dado el precio del subyacente S

1.2 Exponencial y número e

El número $e \approx 2.718$ aparece en todo lo que crece o decrece de forma continua. El **interés continuo** es el caso más común en finanzas: si inviertes 1€ al tipo r durante T años con capitalización continua, obtienes e^{rT} euros.

$$\text{Capital final} = P \cdot e^{(r \cdot T)}$$

P = capital inicial, r = tipo de interés anual, T = tiempo en años

■ Ejemplo

Inviertes 1.000€ al 5% continuo durante 2 años. Capital final = $1000 \cdot e^{(0.05 \cdot 2)} = 1000 \cdot e^{0.10} \approx 1105.17\text{€}$

■ **Recuerda:** $e^0 = 1$, $e^1 \approx 2.718$, $e^{-x} = 1/e^x$. El descuento de flujos futuros usa e^{-rT} para traer dinero al presente.

1.3 Logaritmo natural

El logaritmo natural $\ln(x)$ es la operación inversa de la exponencial. Si $e^y = x$, entonces $\ln(x) = y$. En finanzas se usa para calcular **retornos logarítmicos**, que tienen propiedades matemáticas mucho más cómodas que los retornos simples.

$$\text{Retorno log} = \ln(S_t / S_{t-1}) \approx (S_t - S_{t-1}) / S_{t-1} \text{ para cambios pequeños}$$

La aproximación es muy buena para movimientos diarios típicos (< 5%)

■ ¿Por qué log-retornos?

Si el precio sube +10% y luego baja -10%, con retornos simples acabas en 0.99 (pierdes 1%). Con log-retornos: $\ln(1.10) + \ln(0.90) = 0.095 - 0.105 = -0.010$, que da el mismo resultado pero los log-retornos SÍ son aditivos: el retorno total es la suma de los diarios.

- **$\ln(a \cdot b) = \ln(a) + \ln(b)$** — los log-retornos se suman en el tiempo
- **$\ln(e^x) = x$** — logaritmo y exponencial se cancelan
- **$\ln(1) = 0$** — si no hay cambio de precio, el retorno es cero

2.1 ¿Qué es una derivada?

La derivada de una función mide cómo cambia su valor cuando cambia ligeramente su entrada. Intuitivamente: es la **pendiente** de la función en un punto. En finanzas, los Greeks de las opciones son exactamente derivadas del precio de la opción respecto a distintas variables.

$$f'(x) = df/dx = \lim_{h \rightarrow 0} [f(x+h) - f(x)] / h$$

La derivada como límite del cociente incremental

No hace falta que calcules límites a mano. Lo importante es la intuición y conocer las reglas básicas.

2.2 Reglas de derivación esenciales

Regla	Fórmula	Ejemplo
Potencia	$d/dx [x^n] = n \cdot x^{(n-1)}$	$d/dx [x^2] = 2x$
Constante	$d/dx [c] = 0$	$d/dx [5] = 0$
Exponencial	$d/dx [e^x] = e^x$	La exponencial es su propia derivada
Logaritmo	$d/dx [\ln(x)] = 1/x$	$d/dx [\ln(S)] = 1/S$
Regla de la cadena	$d/dx [f(g(x))] = f'(g(x)) \cdot g'(x)$	$d/dx [e^{(2x)}] = e^{(2x)} \cdot 2 = 2e^{(2x)}$
Suma	$d/dx [f+g] = f' + g'$	Derivar término a término
Producto	$d/dx [f \cdot g] = f' \cdot g + f \cdot g'$	Regla del producto

2.3 Derivadas parciales

Cuando una función depende de varias variables (como el precio de una opción, que depende de S , K , T , r y σ), la **derivada parcial** mide el cambio respecto a una variable manteniendo las demás fijas. Se escribe $\partial f / \partial x$.

Si $f(S, \sigma)$ = precio de la opción, entonces $\partial f / \partial S$ = Delta, $\partial f / \partial \sigma$ = Vega

Los Greeks son derivadas parciales del precio de la opción respecto a cada parámetro

— ■ Intuición de Delta

Delta = $\partial C / \partial S \approx 0.5$ significa que si el subyacente sube 1€, el precio de la call sube aproximadamente 0.50€. Es la sensibilidad de primer orden al precio del subyacente.

2.4 Derivadas de segundo orden

La segunda derivada mide la curvatura de la función, es decir, cómo cambia la pendiente. En opciones, la segunda derivada del precio respecto al subyacente es **Gamma**.

$$\text{Gamma} = \partial^2 C / \partial S^2 = d(\text{Delta}) / dS$$

Gamma mide cuánto cambia Delta cuando se mueve el subyacente

■ **Recuerda:** Gamma alto → Delta cambia mucho → necesitas rebalancear el hedge con frecuencia.
Gamma es especialmente grande para opciones at-the-money cerca del vencimiento.

3.1 ¿Qué es una integral?

La integral es la operación inversa de la derivada. Geométricamente, la integral definida de f entre a y b es el **área bajo la curva** de f en ese intervalo. En probabilidad, la integral de una función de densidad entre dos valores nos da la probabilidad de que la variable caiga en ese rango.

$$\int_{[a \rightarrow b]} f(x) \, dx = \text{área bajo } f(x) \text{ entre } a \text{ y } b$$

El símbolo $\int$ es una S alargada (de 'suma'): es la suma de infinitas franjas infinitamente finas

3.2 Regla fundamental del cálculo

Si $F'(x) = f(x)$, entonces F es la **primitiva** de f y se cumple:

$$\int_{[a \rightarrow b]} f(x) \, dx = F(b) - F(a)$$

Basta encontrar la primitiva y evaluar en los extremos

- $\int x^n \, dx = x^{(n+1)} / (n+1) + C$
- $\int e^x \, dx = e^x + C$
- $\int 1/x \, dx = \ln|x| + C$

3.3 Integrales en probabilidad y finanzas

En finanzas cuantitativa, las integrales aparecen sobre todo en la **función de distribución acumulada (CDF)** de la normal estándar, que es el corazón de Black-Scholes. No necesitas calcularla a mano: existe la función $N(x)$ que Python evalúa directamente con `scipy.stats.norm.cdf(x)`.

$$N(d) = \int_{[-\infty \rightarrow d]} (1/\sqrt{2\pi}) \cdot e^{-t^2/2} \, dt$$

$N(d)$ es la probabilidad de que una variable normal estándar sea menor que d

—■ $N(x)$ en Black-Scholes

En la fórmula de Black-Scholes, $N(d1)$ y $N(d2)$ representan probabilidades ajustadas al riesgo. $N(d2)$ es aproximadamente la probabilidad de que la opción expire in-the-money. Cuando $d \rightarrow +\infty$, $N(d) \rightarrow 1$. Cuando $d \rightarrow -\infty$, $N(d) \rightarrow 0$.

■ **Recuerda:** No necesitas integrar a mano en el curso. Lo importante es entender que $N(x)$ es un área bajo la curva normal y que Python la calcula al instante con `norm.cdf(x)`.

4.1 Vectores

Un vector es una lista ordenada de números. En finanzas, un **vector de pesos de cartera** $w = [w_1, w_2, w_3]$ indica qué fracción del capital está en cada activo. Un **vector de retornos** $r = [r_1, r_2, r_3]$ recoge el retorno de cada activo.

$$w = [0.5, 0.3, 0.2] \rightarrow \text{50\% en activo 1, 30\% en activo 2, 20\% en activo 3}$$

La suma de pesos debe ser 1 (o 100%)

El **producto escalar** (dot product) de dos vectores multiplica elemento a elemento y suma:

$$w \cdot r = w_1 \cdot r_1 + w_2 \cdot r_2 + w_3 \cdot r_3 = \text{retorno total de la cartera}$$

En NumPy: `np.dot(w, r)` o `w @ r`

4.2 Matrices

Una matriz es una tabla rectangular de números. En finanzas, la **matriz de covarianzas** Σ recoge cómo se mueven juntos todos los activos de una cartera. Es cuadrada y simétrica.

$$\Sigma[i,j] = \text{Cov}(r_i, r_j) \rightarrow \text{cómo se mueven juntos los activos } i \text{ y } j$$

La diagonal de Σ contiene las varianzas de cada activo: $\Sigma[i,i] = \text{Var}(r_i)$

■ Varianza de una cartera

$\text{Var}(\text{cartera}) = w^T \cdot \Sigma \cdot w$ Donde w es el vector de pesos (columna), w^T su traspuesta (fila) y Σ la matriz de covarianzas. En NumPy: `var_cartera = w @ cov_matrix @ w`

4.3 Operaciones matriciales esenciales

- **Suma:** $A + B$ — suma elemento a elemento (mismas dimensiones)
- **Producto matricial:** $A \cdot B$ — no es elemento a elemento; las columnas de A deben coincidir con las filas de B
- **Traspuesta:** A^T — refleja la matriz por la diagonal principal
- **Inversa:** A^{-1} tal que $A \cdot A^{-1} = I$ (la identidad) — `np.linalg.inv(A)`
- **Descomposición de Cholesky:** $\Sigma = L \cdot L^T$ — usada para simular activos correlacionados

4.4 Correlación vs. Covarianza

La covarianza mide la relación lineal entre dos activos pero depende de las unidades. La correlación es la versión normalizada y siempre está entre -1 y +1:

$$\rho_{\{i,j\}} = \text{Cov}(r_i, r_j) / (\sigma_i \cdot \sigma_j)$$

$\rho = 1$: se mueven perfectamente juntos. $\rho = -1$: perfectamente opuestos. $\rho = 0$: independientes

■ **Recuerda:** Correlación no implica causalidad. Dos activos pueden estar correlacionados por un factor común (ej. el ciclo económico) sin que uno cause el movimiento del otro.

5.1 Conceptos básicos

La probabilidad es el lenguaje matemático de la incertidumbre. En finanzas, casi todo es incierto: precios futuros, retornos, volatilidad. Modelamos esa incertidumbre con **variables aleatorias** y sus distribuciones.

- **Experimento aleatorio:** proceso con resultado incierto (precio de mañana)
- **Variable aleatoria X:** función que asigna un número a cada resultado posible
- **P(A):** probabilidad del evento A, entre 0 y 1
- **P(A) + P(A^c) = 1:** la probabilidad del evento y su complementario suman 1

5.2 Esperanza y varianza

La **esperanza** $E[X]$ es el valor medio de una variable aleatoria: el promedio ponderado por probabilidades. La **varianza** $\text{Var}(X)$ mide cuánto se dispersan los valores alrededor de la media.

$$E[X] = \sum x_i \cdot P(X = x_i) \text{ (caso discreto)}$$

Para variables continuas: $E[X] = \int x \cdot f(x) dx$

$$\text{Var}(X) = E[(X - E[X])^2] = E[X^2] - (E[X])^2$$

La desviación estándar $\sigma = \sqrt{\text{Var}(X)}$ está en las mismas unidades que X

■ En finanzas

Si los retornos diarios son una variable aleatoria R, $E[R]$ es el retorno esperado (la 'deriva') y $\sigma = \sqrt{\text{Var}(R)}$ es la volatilidad. Cuanto mayor la volatilidad, más impredecible es el activo.

5.3 Propiedades importantes de la esperanza

- **Linealidad:** $E[aX + b] = a \cdot E[X] + b$
- **Suma:** $E[X + Y] = E[X] + E[Y]$ siempre
- **Producto (si independientes):** $E[X \cdot Y] = E[X] \cdot E[Y]$
- **Varianza de la suma:** $\text{Var}(X+Y) = \text{Var}(X) + \text{Var}(Y) + 2 \cdot \text{Cov}(X, Y)$

5.4 Distribución normal

La distribución normal (o gaussiana) es la más importante en finanzas. Se define por dos parámetros: media μ y desviación estándar σ . Los retornos logarítmicos de los activos financieros se modelan

habitualmente como normales (aunque en la realidad tengan colas más gordas).

$$X \sim N(\mu, \sigma^2) \rightarrow f(x) = (1/(\sigma\sqrt{2\pi})) \cdot e^{-(x-\mu)^2/(2\sigma^2)}$$

La curva en forma de campana; simétrica alrededor de μ

- **Regla 68-95-99.7:** el 68% de los valores cae en $[\mu-\sigma, \mu+\sigma]$, el 95% en $[\mu-2\sigma, \mu+2\sigma]$, el 99.7% en $[\mu-3\sigma, \mu+3\sigma]$
- **Normal estándar $Z \sim N(0,1)$:** media 0 y desviación 1. Cualquier normal se estandariza: $Z = (X-\mu)/\sigma$

—■ En Python

```
from scipy.stats import norm
norm.pdf(x, mu, sigma) # densidad en el punto x
norm.cdf(x, mu, sigma) # P(X ≤ x)
norm.ppf(0.05, mu, sigma) # percentil 5% → VaR al 95%
```

5.5 Asimetría y curtosis (skewness y kurtosis)

Los retornos reales de mercado no son perfectamente normales: tienen **colas gordas** (más eventos extremos de lo esperado) y a veces asimetría (más caídas bruscas que subidas).

- **Skewness = 0** → distribución simétrica (como la normal)
- **Skewness < 0** → cola izquierda más larga (más riesgo de caídas extremas)
- **Kurtosis = 3** → normal estándar ('mesocúrtica')
- **Kurtosis > 3** → colas más gordas que la normal ('leptocúrtica'): los eventos extremos son más frecuentes

■ **Recuerda:** Un modelo que asume normalidad puede subestimar gravemente la probabilidad de caídas extremas (crashes). Los eventos de $\pm 3\sigma$ son mucho más frecuentes en los mercados reales que en una normal teórica.

6.1 Estadística descriptiva

Antes de modelar, hay que describir los datos. Los estadísticos descriptivos resumen la información clave de una serie de retornos.

Estadístico	Fórmula	Significado financiero
Media (μ)	$\sum x_i / N$	Retorno promedio
Varianza (σ^2)	$\sum (x_i - \mu)^2 / (N-1)$	Dispersión cuadrada
Desv. estándar (σ)	$\sqrt{\text{varianza}}$	Volatilidad
Mediana	Valor central ordenado	Retorno 'típico' robusto a extremos
Percentil p	Valor que deja p% por debajo	VaR al (100-p)% de confianza
Skewness	$E[(X-\mu)^3] / \sigma^3$	Asimetría de los retornos
Kurtosis	$E[(X-\mu)^4] / \sigma^4$	Peso de las colas (normal=3)

6.2 Volatilidad: el concepto más usado en finanzas cuantitativas

La **volatilidad histórica** de un activo se calcula como la desviación estándar de sus retornos logarítmicos diarios, anualizada multiplicando por $\sqrt{252}$ (días de trading en un año).

$$\sigma_{\text{anual}} = \sigma_{\text{diaria}} \cdot \sqrt{252}$$

Porque la varianza es aditiva en el tiempo: $\text{Var}(T \text{ días}) = T \cdot \text{Var}(1 \text{ día})$

■ Cálculo paso a paso

1. Calcula log-retornos: $r_i = \ln(S_i / S_{i-1})$ 2. Calcula la media de los retornos: μ 3. Calcula la desviación estándar diaria: $\sigma_d = \sqrt{[\sum (r_i - \mu)^2 / (N-1)]}$ 4. Anualiza: $\sigma_{\text{anual}} = \sigma_d \cdot \sqrt{252}$ En Python: `sigma = np.std(log_returns, ddof=1) * np.sqrt(252)`

6.3 Covarianza y correlación: repaso estadístico

La covarianza mide si dos activos tienden a moverse en la misma dirección. Se calcula como la media del producto de las desviaciones de cada activo:

$$\text{Cov}(X,Y) = \sum (x_i - \mu_x)(y_i - \mu_y) / (N-1)$$

En Python: `np.cov(retornos_X, retornos_Y)[0,1]`

La **matriz de covarianzas** para una cartera de n activos tiene dimensión $n \times n$ y contiene todas las covarianzas posibles entre pares de activos:

$$\Sigma = \text{np.cov}(\text{matriz_retornos}) \rightarrow \text{matriz } n \times n$$

La matriz de correlaciones: $R = \text{np.corrcoef}(\text{matriz_retornos})$

6.4 La Ley de los Grandes Números y el Teorema Central del Límite

Estos dos teoremas son el fundamento matemático de por qué funciona la simulación Monte Carlo:

- **Ley de los Grandes Números:** a medida que aumenta el número de muestras, la media muestral converge a la media real $E[X]$. Por eso más simulaciones $\rightarrow$ estimación más precisa.
- **Teorema Central del Límite (TCL):** la suma de muchas variables aleatorias independientes (con varianza finita) se aproxima a una distribución normal, independientemente de la distribución original. Esto justifica modelar los retornos acumulados como normales.

$$\text{Error Monte Carlo} \propto 1/\sqrt{N}$$

Para reducir el error a la mitad, necesitas 4 veces más simulaciones

■ **Recuerda:** El TCL tiene límites importantes en finanzas: cuando los retornos tienen colas muy gordas o están muy correlacionados, la convergencia a la normal es mucho más lenta de lo esperado.

7.1 ¿Qué es un proceso estocástico?

Un **proceso estocástico** es una colección de variables aleatorias indexadas por el tiempo: $\{X(t), t \geq 0\}$. En cada instante t , $X(t)$ es una variable aleatoria. El precio de una acción es el ejemplo más natural: en cada momento es incierto, pero no completamente: depende de lo que pasó antes.

- **Trayectoria:** una realización concreta del proceso (un camino de precios posible)
- **Distribución marginal:** la distribución de $X(t)$ para un t fijo
- **Propiedad de Markov:** el futuro solo depende del presente, no del pasado

7.2 El Movimiento Browniano estándar

El **Movimiento Browniano $W(t)$** (o proceso de Wiener) es el proceso estocástico más fundamental en finanzas. Sus propiedades definen el tipo de aleatoriedad que asumimos en los mercados:

- $W(0) = 0$ — empieza en cero
- Los incrementos $W(t) - W(s)$ son independientes para intervalos no solapados
- $W(t) - W(s) \sim N(0, t-s)$ — incrementos normales con varianza proporcional al tiempo
- Las trayectorias son continuas pero no diferenciables en ningún punto

$$\Delta W \approx \varepsilon \cdot \sqrt{\Delta t} \text{ donde } \varepsilon \sim N(0,1)$$

Discretización: así se simula el BM paso a paso en Python

■ En Python

```
import numpy as np
N = 252 # pasos
dt = 1/252
dW = np.random.normal(0, np.sqrt(dt), N) # incrementos BM
W = np.cumsum(dW) # trayectoria del BM
```

7.3 El Movimiento Browniano Geométrico (MBG)

El precio de una acción no puede ser negativo y sus retornos porcentuales (no absolutos) son los que se distribuyen normalmente. El **MBG** captura exactamente esto: los log-retornos son normales y el precio nunca puede bajar de cero.

La ecuación diferencial estocástica (EDE) del MBG es:

$$dS = \mu \cdot S \cdot dt + \sigma \cdot S \cdot dW$$

μ = deriva (retorno esperado), σ = volatilidad, dW = incremento browniano

La solución exacta es:

$$S(t) = S_0 \cdot \exp\left(\left(\mu - \frac{\sigma^2}{2}\right) \cdot t + \sigma \cdot W(t)\right)$$

El término $-\sigma^2/2$ es la corrección de Itô: ajusta la deriva del log-precio

■ ¿Por qué $\mu - \sigma^2/2$ y no μ ?

Porque la media de e^X no es $e^{\text{media de } X}$. Si $X \sim N(\mu, \sigma^2)$, entonces $E[e^X] = e^{\mu + \sigma^2/2}$. La corrección $-\sigma^2/2$ garantiza que $E[S(t)] = S_0 \cdot e^{\mu t}$, que es lo que queremos.

7.4 Conexión con Black-Scholes

Black-Scholes parte de asumir que el subyacente sigue un MBG y construye una cartera sin riesgo (el activo + opciones) cuyo valor debe crecer al tipo libre de riesgo r . El resultado es una ecuación en derivadas parciales (EDP) cuya solución es la fórmula cerrada:

$$C = S \cdot N(d_1) - K \cdot e^{-rT} \cdot N(d_2) \quad d_1 = \left[\ln(S/K) + (r + \sigma^2/2) \cdot T \right] / (\sigma \sqrt{T}) \quad d_2 = d_1 - \sigma \sqrt{T}$$

C = precio call, S = subyacente, K = strike, r = tipo libre riesgo, T = tiempo, σ = volatilidad, N = CDF normal

- $N(d_1)$: delta de la opción, fracción del subyacente en la cartera replicante
- $N(d_2)$: probabilidad (bajo medida neutral al riesgo) de que la opción expire in-the-money
- $K \cdot e^{-rT}$: valor presente del strike (descuento continuo del módulo 1)

■ **Recuerda:** Cada pieza de la fórmula Black-Scholes usa matemáticas de los capítulos anteriores: el logaritmo natural (cap. 1), la exponencial y el descuento (cap. 1), la derivada para los Greeks (cap. 2), la integral $N(d)$ (cap. 3) y la distribución normal (cap. 5).

¿Y ahora qué? Con este bagaje matemático ya tienes todo lo necesario para afrontar el curso Quant Club. A lo largo de los módulos irás viendo cómo cada uno de estos conceptos se traduce directamente en código Python y en herramientas de pricing, simulación y gestión de riesgo reales.